DỰ ĐOÁN CHỈ SỐ HẠNH PHÚC DỰA TRÊN THÓI QUEN SỐNG

1st Dương Quốc Anh
IE313.Q11
Trường Đại học Công nghệ Thông tin
22520043@gm.uit.edu.vn

2nd Nguyễn Hữu Thiện
IE313.Q11
Trường Đại học Công nghệ Thông tin
22521389@gm.uit.edu.vn

3rd Phan Thị Tường Vi
IE313.Q11
Trường Đại học Công nghệ Thông tin
22521658@gm.uit.edu.vn

4th Lê Thị Ánh Xuân
IE313.Q11
Trường Đại học Công nghệ Thông tin
22521714@gm.uit.edu.vn

***Tóm tắt* — Hiện nay, chất lượng cuộc sống và sức khỏe tinh thần không còn là khái niệm xa lạ đối với cộng đồng và xã hội. Việc xây dựng các mô hình dự đoán chỉ số hạnh phúc đóng góp ý nghĩa quan trọng vào quá trình ra quyết định cá nhân nhằm cải thiện lối sống. Trong bài báo này, nhóm thực hiện thu thập dữ liệu về thói quen sinh hoạt từ nền tảng Kaggle để làm cơ sở phân tích. Nhóm đã sử dụng nhiều mô hình khác nhau bao gồm Linear Regression, Lasso Regression, K-Nearest Neighbors (KNN), Multilayer Perceptron (MLP), Light Gradient Boosting Machine (LightGBM), eXtreme Gradient Boosting (XGBoost) và Categorical Boosting (CatBoost) để tìm ra mô hình dự báo tối ưu nhất. Kết quả thực nghiệm cho thấy các thuật toán học máy nâng cao, đặc biệt là các phương pháp Boosting, thể hiện hiệu suất vượt trội: CatBoost đạt độ chính xác cao nhất với hệ số xác định (R^2) là 0.9438, theo sát là XGBoost với R^2 đạt 0.9426 và LightGBM với 0.9424. Mô hình đạt kết quả tệ nhất là Linear Regression với R^2 là 0.8309.**

Từ khóa — dự đoán chỉ số hạnh phúc, Boosting, Linear Regression, Lasso Regression, K-Nearest Neighbors (KNN), Multi-Layer Perceptron (MLP), Light Gradient Boosting Machine (LightGBM), eXtreme Gradient Boosting (XGBoost), Categorical Boosting (CatBoost)

I. GIỚI THIỆU

Việc tạo nên một cuộc sống hạnh phúc và cân bằng luôn là mục tiêu trong chiến lược phát triển con người của mọi quốc gia.

Đối với Chính phủ, chỉ số hạnh phúc là thước đo quan trọng để đánh giá hiệu quả của các chính sách an sinh xã hội. Việc nắm bắt được các yếu tố ảnh hưởng đến hạnh phúc giúp xây dựng các chiến lược y tế công cộng hiệu quả, giảm thiểu gánh nặng lên hệ thống y tế và nâng cao chất lượng nguồn nhân lực.

Đối với các tổ chức và doanh nghiệp, việc thấu hiểu sức khỏe tinh thần là cơ sở để xây dựng môi trường làm việc tích cực. Một lực lượng lao động hạnh phúc sẽ mang lại năng suất cao hơn.

Đối với mỗi cá nhân, việc nhận thức rõ về các yếu tố cấu thành hạnh phúc mang giúp mỗi người có thể xây dựng một lối sống lành mạnh nhằm tối ưu hóa sức khỏe thể chất và tinh thần của bản thân.

Trong lĩnh vực khoa học dữ liệu và tâm lý học, việc dự đoán chỉ số hạnh phúc dựa trên các yếu tối thói quen sống là một nhiệm vụ quan trọng và đầy thách thức. Để giúp các cá nhân và chuyên gia đưa ra những quyết định điều chỉnh lối sống thông minh, việc sử dụng các thuật toán và mô hình dự đoán đã trở thành một phương pháp phổ biến và hữu ích.

Việc ứng dụng các thuật toán dự báo chỉ số hạnh phúc mang lại nhiều lợi ích quan trọng. Thứ nhất, nó giúp xác định các xu hướng và yếu tố tác động mạnh mẽ nhất (như giấc ngủ, vận động, công việc), từ đó giúp cá nhân đưa ra quyết định thay đổi hoặc duy trì thói quen. Thứ hai, nó cung cấp phương tiện để đánh giá sự cải thiện tâm trạng và nguy cơ căng thẳng của các lối sống cụ thể. Thứ ba, các thuật toán này còn hỗ trợ quản lý sức khỏe cá nhân một cách chủ động. Tuy nhiên, dự đoán tâm lý con người không phải là nhiệm vụ dễ dàng và luôn tiềm ẩn những sự không chắc chắn do tính phức tạp của hành vi con người. Do đó, việc sử dụng các mô hình học máy tiên tiến là công cụ đắc lực để lượng hóa và đánh giá các quyết định này.

Trong bài báo này, nhóm sẽ sử dụng các mô hình gồm Linear Regression, Lasso Regression, K-Nearest Neighbors (KNN), Multilayer Perceptron (MLP), Light Gradient Boosting Machine (LightGBM), eXtreme Gradient Boosting (XGBoost) và Categorical Boosting (CatBoost) để dự đoán chỉ số hạnh phúc dựa trên dữ liệu về thói quen sống. Từ đó, nhóm sẽ đánh giá và so sánh hiệu suất của 7 mô hình trên để lựa chọn ra mô hình phù hợp và chính xác nhất.

II. NGHIÊN CỨU LIÊN QUAN

Chỉ số hạnh phúc là một trong những thước đo quan trọng phản ánh sự thịnh vượng và tiến bộ xã hội của một quốc gia, thu hút sự quan tâm lớn từ các nhà hoạch định chính sách và giới nghiên cứu. Nhiều công trình nghiên cứu đã được thực hiện nhằm dự đoán chỉ số hạnh phúc thông qua các mô hình học máy và thống kê tiên tiến khác nhau.

Để nâng cao độ chính xác của dự báo, các kỹ thuật học tập kết hợp (Ensemble Learning) và mô hình lai ghép đang nhận được sự quan tâm lớn. Md Amir Hamja và cộng sự (2025) [1] đã nghiên cứu dự đoán điểm số hạnh phúc trong bối cảnh đại dịch toàn cầu bằng cách sử dụng kỹ thuật Stacking và Blending. Họ kết hợp các mô hình cơ sở như Random Forest, XGBoost với các mô hình học sâu như LSTM và MLP. Kết quả thực nghiệm cho thấy mô hình Blending RGMLL (tổ hợp RF, GBM, MLP, LSTM và Linear Regression) đạt hiệu suất vượt trội nhất với hệ số xác định $R^2 = 0.85$, sai số RMSE = 0.38, cải thiện đáng kể so với các mô hình đơn lẻ.

Tương tự, Boxu Yang và Xiang Xie (2025) [2] đã đề xuất một khung dự báo tích hợp mới lạ bằng cách kết hợp phân cụm K-Means với các thuật toán học máy giám sát. Khi so sánh các mô hình, Random Forest kết hợp phân cụm đạt hiệu suất tốt nhất với $R^2 = 0.841$, vượt trội hơn so với XGBoost ($R^2 = 0.738$) và Linear Regression ($R^2 = 0.621$). Nghiên cứu chỉ ra rằng việc tích hợp thông tin phân cụm giúp cải thiện độ chính xác khoảng 12%.

Bên cạnh các mô hình lai ghép, việc so sánh hiệu quả giữa các thuật toán Boosting (tăng cường) và các phương pháp hồi quy truyền thống cũng là chủ đề được khai thác sâu. Kemi Akanbi và cộng sự (2024) [3] đã sử dụng dữ liệu từ Báo cáo Hạnh

XXX-X-XXXX-XXXX-X/XX/$XX.00 ©20XX IEEE

phúc Thế giới của 156 quốc gia để huấn luyện các mô hình Random Forest, XGBoost và Lasso Regressor. Kết quả của họ khẳng định sự ưu việt của XGBoost với $R^2 = 85.03\%$ và sai số MSE = 0.0032, trong khi Random Forest đạt 83.68% và Lasso Regressor đạt 80.61%.

Đồng quan điểm này, Yikai Feng (2025) [4] đã thực hiện phân tích dựa trên dữ liệu và kết luận rằng Gradient Boosting là mô hình tối ưu nhất với $R^2 = 0.83$, theo sau là Random Forest ($R^2 = 0.82$), trong khi Linear Regression cho thấy hiệu suất thấp nhất ($R^2 = 0.77$). Các nghiên cứu này đều thống nhất rằng các mô hình phi tuyến tính, đặc biệt là họ Boosting, có khả năng xử lý dữ liệu xã hội tốt hơn hẳn so với hồi quy tuyến tính.

Tuy nhiên, hiệu suất của thuật toán còn phụ thuộc vào cách tiếp cận bài toán là hồi quy hay phân loại. Trong nghiên cứu của Sadullah Çelik và cộng sự (2025) [5] về bài toán phân loại mức độ hạnh phúc (chia nhóm quốc gia), kết quả lại cho thấy một góc nhìn khác. Khi so sánh độ chính xác của 6 thuật toán, các phương pháp truyền thống như Logistic Regression, Decision Tree và SVM lại đạt hiệu quả cao nhất (86.2%), trong khi XGBoost lại cho kết quả thấp hơn (79.3%). Điều này cho thấy sự cần thiết phải lựa chọn thuật toán phù hợp với đặc thù dữ liệu và mục tiêu dự báo cụ thể.

Tổng hợp lại, các nghiên cứu trên đã cung cấp nền tảng vững chắc cho việc ứng dụng học máy trong dự báo hạnh phúc. Kế thừa các kết quả này, nhóm sẽ sử dụng các thuật toán như Linear Regression, Lasso Regression, KNN, MLP, bên cạnh đó tập trung khai thác sức mạnh của các thuật toán Boosting hiện đại (như CatBoost, XGBoost, LightGBM) trên tập dữ liệu về thói quen sống cá nhân để đạt được độ chính xác tối ưu.

III. PHƯƠNG PHÁP

A. Tổng quan bộ dữ liệu

Nhóm sử dụng bộ dữ liệu được thu thập từ nền tảng Kaggle, tập trung vào việc phân tích mối tương quan giữa thói quen lối sống và chỉ số hạnh phúc. Bộ dữ liệu bao gồm tổng cộng 24998 quan sát (dòng), đại diện cho 24998 cá nhân khác nhau. Dữ liệu chứa 18 thuộc tính (cột), bao gồm các thông tin về nhân khẩu học, sức khỏe tinh thần, thói quen sinh hoạt hàng ngày và chỉ số hạnh phúc.

Trong 18 thuộc tính của bộ dữ liệu, Happiness_Score được xác định là biến mục tiêu cần dự báo. Các thuộc tính còn lại đóng vai trò là các biến đặc trưng đầu vào.

Chi tiết các biến và ý nghĩa được trình bày trong Bảng 1 dưới đây:

Bảng 1. Mô tả các biến trong bộ dữ liệu

Tên biến	Loại dữ liệu	Ý nghĩa
User_ID	Định danh	Mã định danh duy nhất của từng cá nhân
Age	Định lượng	Tuổi
Gender	Định danh	Giới tính
Occupation	Định danh	Nghề nghiệp
Country	Định danh	Quốc gia sinh sống
Mental_Health_Condition	Định danh (Nhị phân)	Tình trạng sức khỏe tinh thần
Severity	Thứ bậc	Mức độ nghiêm trọng của vấn đề sức khỏe tinh thần
Consultation_History	Định danh (Nhị phân)	Lịch sử thăm khám hoặc tư vấn tâm lý
Stress_Level	Thứ bậc	Mức độ căng thẳng trong cuộc sống
Sleep_Hours	Định lượng	Số giờ ngủ trung bình mỗi ngày
Work_Hours	Định lượng	Số giờ làm việc trung bình mỗi tuần
Physical_Activity_Hours	Định lượng	Số giờ vận động thể chất
Social_Media_Usage	Định lượng	Thời gian sử dụng mạng xã hội
Diet_Quality	Thứ bậc	Chất lượng bữa ăn
Smoking_Habit	Thứ bậc	Thói quen hút thuốc
Alcohol_Consumption	Thứ bậc	Mức độ tiêu thụ rượu bia
Medication_Usage	Định danh (Nhị phân)	Việc sử dụng thuốc (liên quan đến sức khỏe)
Happiness_Score	Định lượng	Chỉ số hạnh phúc

B. Tiền xử lý dữ liệu

1. Mã hóa dữ liệu

Do dữ liệu ban đầu chứa nhiều định dạng khác nhau, nhóm áp dụng các kỹ thuật mã hóa phù hợp cho từng loại biến:

- Biến nhị phân: Các biến nhị phân được mã hóa thành 0 và 1.
- Biến thứ bậc: Các biến định tính có tính chất xếp hạng được mã hóa thành các số nguyên để bảo toàn thứ tự. Ví dụ: Stress_Level (Low=1, Medium=2, High=3)
- Biến định danh: Các biến không có thứ tự như Country, Occupation, Gender được xử lý bằng kỹ thuật One-Hot Encoding (hàm get_dummies), chuyển đổi thành các vector nhị phân (giá trị 1 nếu thuộc nhóm, 0 nếu không thuộc) để tránh tạo ra quan hệ thứ bậc giả.

Chi tiết kết quả mã hóa dữ liệu được trình bày trong Bảng 2 dưới đây:

Bảng 2. Kết quả mã hóa dữ liệu

Biến	Miền giá trị	Giá trị mã hóa
Gender	"Male", "Non-binary", "Prefer not to say", "Female"	Giá trị = 1 nếu thuộc nhóm đó; Giá trị = 0 nếu không thuộc

Occupation	“Engineering”, “Healthcare”, “Other”, “IT”, “Sales”, “Education”, “Finance”	Giá trị = 1 nếu thuộc nhóm đó; Giá trị = 0 nếu không thuộc
Country	“Other”, “Australia”, “India”, “USA”, “Canada”, “UK”, “Germany”	Giá trị = 1 nếu thuộc nhóm đó; Giá trị = 0 nếu không thuộc
Severity	“Low”, “Medium”, “High”	1, 2, 3
Consultation_History	“No”, “Yes”	0, 1
Medication_Usage	“No”, “Yes”	0, 1
Stress_Level	“Low”, “Medium”, “High”	1, 2, 3
Diet_Quality	“Unhealthy”, “Average”, “Healthy”	1, 2, 3
Smoking_Habit	“Non-Smoker”, “Occasional Smoker”, “Regular Smoker”, “Heavy Smoker”	0, 1, 2, 3
Alcohol_Consumption	“Non-Drinker”, “Social Drinker”, “Regular Drinker”, “Heavy Drinker”	0, 1, 2, 3
Mental_Health_Condition	“No”, “Yes”	0, 1

2. *Lựa chọn đặc trưng*

Để tối ưu hóa hiệu suất mô hình, nhóm thực hiện phân tích Ma trận tương quan với biến mục tiêu là Happiness_Score:

- Kết quả: Chọn lọc được 8 biến có mức độ tương quan cao nhất: Diet Quality, Mental Health Condition, Stress Level, Alcohol Consumption, Smoking Habit, Physical Activity Hours, Sleep Hours, Work Hours.
- Kiểm định đa cộng tuyến: Kết quả phân tích tương quan giữa 8 biến đầu vào này cho thấy hệ số tương quan giữa chúng rất thấp (xấp xỉ 0). Điều này xác nhận các biến độc lập tuyến tính và phù hợp để đưa vào mô hình dự báo.

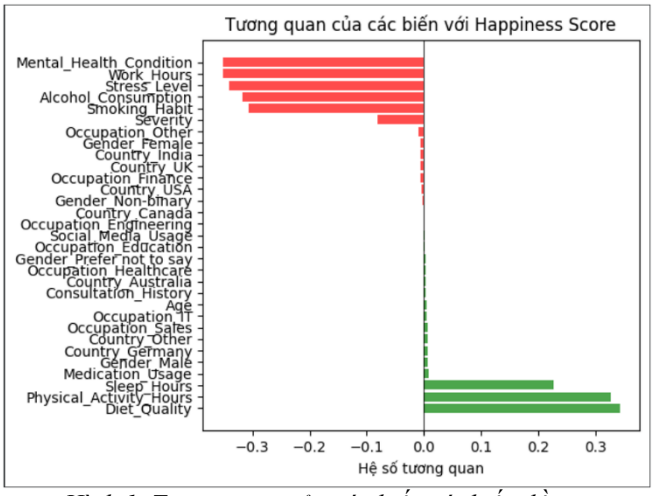

Hình 1. Tương quan của các biến với biến đầu ra

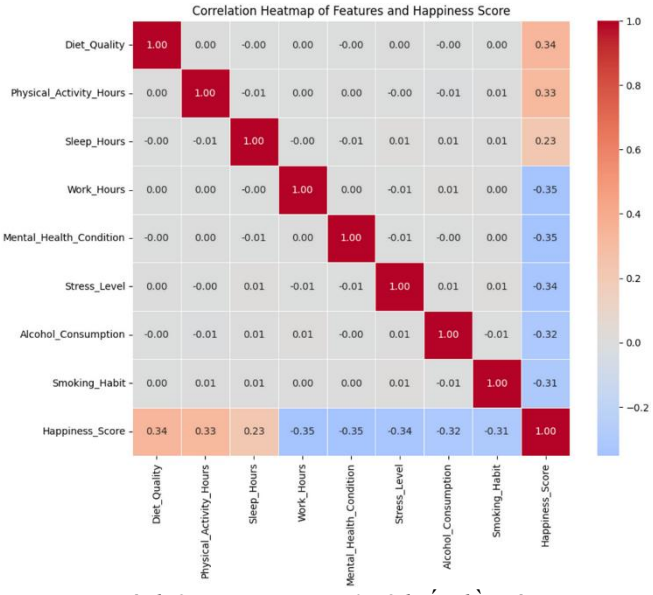

Hình 2. Tương quan của 8 biến đầu vào

3. *Thống kê mô tả*

Đối với 8 biến đặc trưng đã chọn, nhóm thực hiện thống kê mô tả để nắm bắt đặc điểm dữ liệu. Các chỉ số được tính toán bao gồm: các tham số hướng trung tâm (Mean, Median, Mode), độ phân tán (Variance, Std, CV, …) và hình dáng phân phối (Skewness, Kurtosis).

	Mean	Median	Mode
Diet_Quality	1.994160	2.0	2.0
Physical_Activity_Hours	5.011961	5.0	10.0
Sleep_Hours	7.018721	7.0	7.1
Work_Hours	55.127650	55.0	41.0
Mental_Health_Condition	0.500160	1.0	1.0
Stress_Level	2.007201	2.0	2.0
Alcohol_Consumption	1.503520	2.0	3.0
Smoking_Habit	1.502400	1.5	3.0

Hình 3. Các tham số về hướng trung tâm

	Min	Q1	Median	Q3	Max	Range	IQR	Variance	Std	CV
Diet_Quality	1.0	1.0	2.0	3.0	3.0	2.0	2.0	0.661085	0.813071	0.407726
Physical_Activity_Hours	0.0	2.0	5.0	8.0	10.0	10.0	6.0	9.986535	3.160148	0.630521
Sleep_Hours	4.0	5.5	7.0	8.5	10.0	6.0	3.0	3.002441	1.732755	0.246876
Work_Hours	30.0	42.0	55.0	68.0	80.0	50.0	26.0	214.574376	14.648357	0.265717
Mental_Health_Condition	0.0	0.0	1.0	1.0	1.0	1.0	1.0	0.250010	0.500010	0.999700
Stress_Level	1.0	1.0	2.0	3.0	3.0	2.0	2.0	0.661308	0.813208	0.405145
Alcohol_Consumption	0.0	0.0	2.0	3.0	3.0	3.0	3.0	1.255798	1.120624	0.745334
Smoking_Habit	0.0	0.0	1.5	3.0	3.0	3.0	3.0	1.260045	1.122517	0.747149

Hình 4. Các tham số về độ phân tán

	Skewness	Kurtosis
Diet_Quality	0.010685	-1.487257
Physical_Activity_Hours	-0.001218	-1.218849
Sleep_Hours	-0.009192	-1.196770
Work_Hours	-0.002466	-1.196438
Mental_Health_Condition	-0.000640	-2.000160
Stress_Level	-0.013175	-1.487726
Alcohol_Consumption	-0.002915	-1.365903
Smoking_Habit	-0.000899	-1.370221

Hình 5. Các tham số về hình dáng phân phối

4. *Chia tập dữ liệu*

Bộ dữ liệu được chia thành hai tập độc lập theo tỷ lệ 80:20:

- Tập huấn luyện (Training Set - 80%): Gồm khoảng 20.000 mẫu, dùng để xây dựng mô hình.
- Tập kiểm tra (Test Set - 20%): Gồm khoảng 5.000 mẫu, được tách biệt hoàn toàn để đánh giá hiệu suất mô hình.

5. *Chuẩn hóa dữ liệu*

Để đảm bảo các biến số có đơn vị đo lường khác nhau đóng góp bình đẳng vào mô hình, phương pháp Min-Max Scaling được áp dụng để đưa miền giá trị của tất cả các biến đầu vào về khoảng [0, 1].

C. *Mô hình*

1. *Linear Regression*

Linear Regression (Hồi quy tuyến tính) là một phương pháp thống kê và học máy cơ bản, dùng để mô hình hóa mối quan hệ tuyến tính giữa một biến phụ thuộc (mục tiêu) và một hoặc nhiều biến độc lập (dự đoán), tìm ra đường thẳng (hoặc mặt phẳng) phù hợp nhất để dự đoán giá trị của biến mục tiêu dựa trên giá trị các biến đầu vào.

Quá trình hoạt động của Linear Regression gồm một chuỗi các bước liên tiếp và có tính lặp. Trước hết, mô hình nhận vào tập dữ liệu huấn luyện, trong đó mỗi mẫu bao gồm các biến đầu vào và giá trị đầu ra tương ứng. Từ các biến đầu vào này, mô hình tạo ra những giá trị dự đoán ban đầu dựa trên một tập hệ số khởi tạo.

Tiếp theo, các giá trị dự đoán được so sánh với giá trị thực tế để xác định mức độ sai lệch của từng mẫu dữ liệu. Những sai lệch này phản ánh mức độ mô hình dự đoán chưa chính xác. Từ sai lệch đó, mô hình đánh giá tổng mức lỗi trên toàn bộ tập dữ liệu, qua đó biết được mô hình đang phù hợp với dữ liệu ở mức độ nào.

Dựa trên tổng sai lệch thu được, các hệ số của mô hình sẽ được điều chỉnh theo hướng làm giảm sai số chung. Việc điều chỉnh này giúp mô hình dần học được mối quan hệ giữa các biến đầu vào và biến đầu ra. Quá trình dự đoán, so sánh sai số và điều chỉnh hệ số được lặp đi lặp lại nhiều lần cho đến khi sai số không còn giảm đáng kể hoặc đạt đến mức tối ưu. Khi đó, mô hình được xem là đã hoàn tất quá trình học và có thể sử dụng để dự đoán cho dữ liệu mới.

Linear Regression được sử dụng trong bài toán này với mục tiêu làm mô hình baseline, cung cấp mốc so sánh đơn giản và dễ diễn giải. Kết quả của Linear Regression giúp đánh giá mức độ tuyến tính của dữ liệu và làm rõ hiệu quả cải thiện của các mô hình phi tuyến như CatBoost, XGBoost, LightGBM, … trong dự đoán chỉ số hạnh phúc.

Kết quả thu được phương trình:

$$\hat{y} = 0.3407x_1 + 0.3243x_2 + 0.2314x_3 - 0.3485x_4 - 0.3496x_5 - 0.3418x_6 - 0.3133x_7 - 0.3070x_8 - 0.0006$$

Với:

- x_1 = Diet_Quality
- x_2 = Physical_Activity_Hours
- x_3 = Sleep_Hours
- x_4 = Work_Hours
- x_5 = Mental_Health_Condition
- x_6 = Stress_Level
- x_7 = Alcohol_Consumption
- x_8 = Smoking_Habit

2. *Lasso Regression*

Lasso là một phương pháp phân tích hồi quy thực hiện cả hai nhiệm vụ: lựa chọn biến và điều chuẩn (regularization). Đây là một biến thể của mô hình Hồi quy tuyến tính nhưng được bổ sung thêm thành phần phạt nhằm nâng cao độ chính xác dự đoán và khả năng thông dịch của mô hình thống kê.

Khác với hồi quy thông thường (OLS) chỉ tập trung giảm thiểu tổng bình phương sai số (RSS), Lasso tối ưu hóa hàm mục tiêu sau:

$$\min_{\beta}\left\{\sum_{i=1}^{n}\left(y_i - \beta_0 - \sum_{j=1}^{p}\beta_j x_{ij}\right)^2 + \alpha\sum_{j=1}^{p}|\beta_j|\right\}$$

Trong đó:

- RSS (Thành phần đầu tiên): Đo lường sự sai lệch giữa giá trị dự đoán và giá trị thực tế.
- L_1 Penalty (Thành phần thứ hai - $\alpha\sum|\beta_j|$): Tổng giá trị tuyệt đối của các hệ số hồi quy nhân với tham số điều chuẩn α.

Ứng dụng bài toán:

Giai đoạn 1: Chuẩn hóa dữ liệu để đưa tất cả các biến độc lập về cùng một phân phối chuẩn. Vì Lasso Regression rất nhạy cảm với độ lớn của dữ liệu. Nếu không chuẩn hóa, các biến có đơn vị lớn sẽ bị phạt nặng hơn một cách bất công, dẫn đến sai lệch trong việc chọn biến quan trọng. Sau đó, mô hình được huấn luyện trên tập Train và phép biến đổi được áp dụng cho cả tập Train và tập Test nhằm tránh hiện tượng rò rỉ dữ liệu.

Giai đoạn 2: Tối ưu hóa tham số α. Sử dụng LassoCV (Lasso với Cross-Validation). Kiểm thử 100 giá trị Alpha trong khoảng log-scale 10^{-4} đến 10^{2}) kết hợp với kỹ thuật kiểm định chéo 5 lần (5-fold Cross-Validation). Thuật toán tự động hội

tụ và chọn ra giá trị α tối ưu nhất giúp cân bằng giữa độ lệch và phương sai.
Giai đoạn 3: Huấn luyện và đánh giá. Mô hình được huấn luyện lại trên toàn bộ tập Train đã chuẩn hóa với tham số α tốt nhất vừa tìm được.

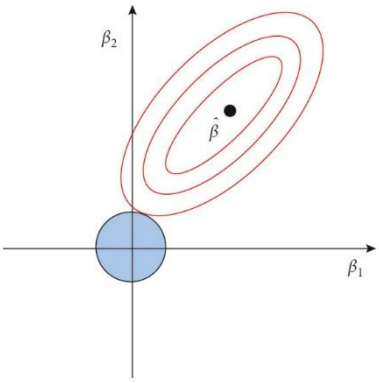

Hình 6. Minh họa ràng buộc chuẩn L1 trong Lasso Regression

3. K-Nearest Neighbors (KNN)

K-Nearest Neighbors (KNN) là một thuật toán học máy có giám sát thuộc nhóm Học dựa trên mẫu (Instance-based learning). Khác với các mô hình tham số cố gắng học một hàm tổng quát từ dữ liệu huấn luyện, KNN là một thuật toán "lười" và phi tham số.
Nguyên lý hoạt động của thuật toán dựa trên giả định rằng các điểm dữ liệu tương đồng sẽ có xu hướng nằm gần nhau trong không gian đặc trưng. Thay vì xây dựng mô hình dự đoán ngay lập tức, hệ thống sẽ lưu trữ toàn bộ dữ liệu huấn luyện. Khi cần dự báo cho một điểm dữ liệu mới, thuật toán sẽ tìm kiếm k điểm dữ liệu gần nhất (láng giềng) trong quá khứ để đưa ra kết luận.
Để xác định mức độ tương đồng giữa các điểm dữ liệu, KNN sử dụng các độ đo khoảng cách. Trong nghiên cứu này, nhóm sử dụng Khoảng cách Euclid. Đây là khoảng cách ngắn nhất giữa hai điểm trong không gian.
Giả sử chúng ta có hai điểm dữ liệu A và B trong không gian n chiều (tương ứng với n đặc trưng đầu vào), khoảng cách Euclid giữa hai điểm được tính theo công thức:

$$d(A,B) = \sqrt{\sum_{i=1}^{n} \left(x_{A_i} - x_{B_i}\right)^2}$$

Trong đó:

- x_{A_i}, x_{B_i} là giá trị của đặc trưng thứ i tại điểm A và điểm B.
- n là tổng số biến đầu vào (trong bài toán này n = 8).

Mặc dù KNN thường được biết đến với bài toán phân loại (dựa trên cơ chế bỏ phiếu đa số), trong nghiên cứu này, nhóm áp dụng KNN cho bài toán Hồi quy để dự đoán Chỉ số hạnh phúc (Happiness Score). Quy trình thực hiện như sau:

- Tính toán: Với mỗi người dùng mới cần dự đoán, thuật toán tính khoảng cách Euclid từ người đó đến tất cả các mẫu trong tập huấn luyện dựa trên 8 đặc trưng lối sống (Giờ ngủ, Giờ làm, Mức độ stress, …).
- Tìm láng giềng: Thuật toán chọn ra k người dùng có khoảng cách nhỏ nhất (tức là có thói quen sinh hoạt tương đồng nhất).
- Tổng hợp kết quả: Giá trị dự báo y (Chỉ số hạnh phúc) sẽ là trung bình cộng giá trị của k láng giềng gần nhất:

$$\hat{y} = \frac{1}{k}\sum_{i=1}^{k} y_i$$

- Lựa chọn tham số k tối ưu: Tham số k (số lượng láng giềng) đóng vai trò quyết định đến hiệu suất mô hình. Nếu k quá nhỏ: Mô hình nhạy cảm với nhiễu, dễ dẫn đến quá khớp (overfitting). Nếu k quá lớn: Mô hình có thể bị làm trơn quá mức, mất đi các đặc điểm cục bộ quan trọng (underfitting).

Trong nghiên cứu này, nhóm đã thực hiện kỹ thuật tinh chỉnh siêu tham số với dải giá trị k chạy từ 1 đến 20. Kết quả thực nghiệm trên tập kiểm thử cho thấy giá trị k = 13 mang lại sai số RMSE thấp nhất và độ chính xác R^2 cao nhất. Do đó, k = 13 được chọn làm cấu hình chính thức cho mô hình dự báo.

4. Multilayer Perceptron (MLP)

Multilayer Perceptron (MLP) là một dạng mạng nơ-ron nhân tạo truyền thẳng (Feedforward Neural Network) cơ bản và phổ biến nhất trong Deep Learning. Khác với các mô hình máy học truyền thống, MLP được thiết kế để mô phỏng cơ chế hoạt động của não bộ con người thông qua việc kết nối các đơn vị xử lý thông tin gọi là "nơ-ron" (neurons).
Sức mạnh của MLP nằm ở khả năng xấp xỉ các hàm phi tuyến tính phức tạp. Thông qua quá trình huấn luyện (training) sử dụng thuật toán lan truyền ngược (Backpropagation), mạng có thể tự điều chỉnh các trọng số liên kết để giảm thiểu sai số dự đoán, từ đó học được các mối quan hệ tiềm ẩn giữa dữ liệu đầu vào và kết quả đầu ra.
Trong nghiên cứu này, nhóm xây dựng một kiến trúc MLP chuyên biệt cho bài toán hồi quy nhằm dự đoán Chỉ số hạnh phúc (Happiness Score). Cấu trúc mạng được thiết kế theo dạng hình tháp, bao gồm 4 lớp xử lý chính (1 lớp đầu vào, 2 lớp ẩn và 1 lớp đầu ra) với thông số chi tiết như sau:
Lớp đầu vào (Input Layer): Lớp này bao gồm 8 nơ-ron, tương ứng với 8 biến đặc trưng đã được lựa chọn từ quá trình tiền xử lý dữ liệu (bao gồm: Chất lượng ăn uống, Giờ ngủ, Giờ làm việc, Mức độ Stress, …). Lớp đầu vào không thực hiện tính toán mà chỉ đóng vai trò tiếp nhận và chuẩn hóa dữ liệu để truyền vào mạng.
Các lớp ẩn (Hidden Layers): Đây là thành phần quan trọng nhất, nơi diễn ra quá trình "tư duy" và trích xuất đặc trưng của mô hình. Nhóm sử dụng 2 lớp ẩn kết nối đầy đủ (Fully Connected Layers). Lớp ẩn 1 gồm 64 nơ-ron, chịu trách nhiệm tiếp nhận dữ liệu thô từ đầu vào và biến đổi chúng sang không gian đặc trưng cao chiều hơn. Lớp ẩn 2: Gồm 32 nơ-ron. Việc giảm số lượng nơ-ron so với lớp trước giúp mạng cô đọng thông tin, loại bỏ nhiễu và tập trung vào các đặc trưng quan trọng nhất trước khi đưa ra quyết định.
Tại cả hai lớp ẩn, nhóm sử dụng hàm kích hoạt ReLU. Hàm ReLU được định nghĩa công thức:

$$f(x) = max(0, x)$$

Việc sử dụng ReLU giúp giải quyết vấn đề biến mất đạo hàm (vanishing gradient) thường gặp trong các mạng sâu, đồng thời cho phép mô hình học được các mối quan hệ phi tuyến tính phức tạp giữa thói quen sinh hoạt và chỉ số hạnh phúc.

Lớp đầu ra (Output Layer): Vì đây là bài toán hồi quy (dự đoán một giá trị thực), lớp đầu ra chỉ bao gồm 1 nơ-ron duy nhất. Nơ-ron này tổng hợp các tín hiệu từ lớp ẩn cuối cùng để trả về kết quả là Happiness Score dự đoán.
Cơ chế hoạt động: Tại mỗi nơ-ron (ngoại trừ lớp đầu vào), giá trị đầu ra được tính toán theo hai bước:

- Tổ hợp tuyến tính: Tính tổng có trọng số của các đầu vào cộng với hệ số bias.

$$z = \sum_{i=1}^{n} w_i x_i + b$$

- Kích hoạt phi tuyến: Áp dụng hàm kích hoạt (ReLU) lên kết quả z để tạo ra tín hiệu đầu ra cho lớp tiếp theo.

Quá trình huấn luyện mô hình được thực hiện bằng cách tối ưu hóa hàm mất mát (Loss Function), thường là Sai số toàn phương trung bình (MSE), để tìm ra bộ trọng số w tối ưu sao cho giá trị dự đoán sát nhất với thực tế.

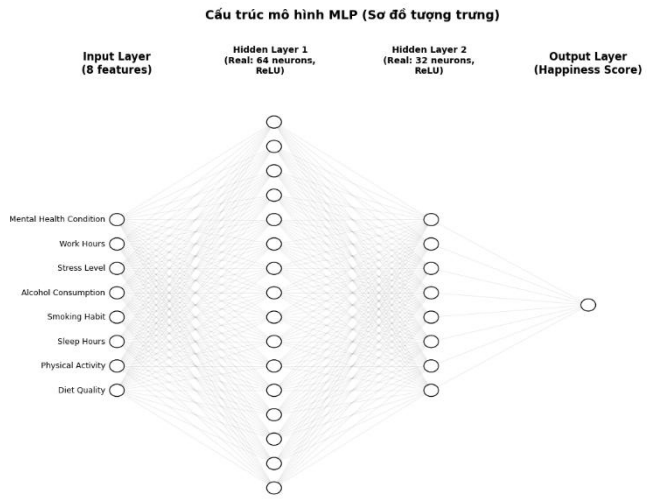

Hình 7. Minh họa cấu trúc mạng MLP

5. *Light Gradient Boosting Machine (LightGBM)*

Light Gradient Boosting Machine (LightGBM) là một thuật toán ensemble dựa trên Gradient Boosting và Decision Tree, được đề xuất bởi Ke et al. (2017) [6], với mục tiêu tối ưu tốc độ huấn luyện và hiệu quả sử dụng bộ nhớ, đặc biệt phù hợp với các tập dữ liệu lớn.
LightGBM áp dụng thuật toán histogram-based để rời rạc hóa các biến liên tục thành các bins, giúp giảm đáng kể chi phí tính toán và bộ nhớ so với việc duyệt toàn bộ các điểm chia. Ngoài ra, mô hình hỗ trợ xử lý biến phân loại trực tiếp mà không cần one-hot encoding thông qua cơ chế tìm điểm chia hiệu quả.
Một điểm khác biệt quan trọng của LightGBM là chiến lược phát triển cây theo hướng leaf-wise, trong đó lá làm giảm hàm loss nhiều nhất sẽ được tiếp tục phân tách, giúp mô hình học nhanh và biểu diễn tốt các quan hệ phi tuyến phức tạp. Tuy nhiên, do cây có xu hướng phát triển sâu không cân đối, LightGBM có nguy cơ overfitting nếu không kiểm soát chặt chẽ các siêu tham số và regularization. Nhờ các cải tiến này, LightGBM được sử dụng rộng rãi trong các bài toán hồi quy và phân loại quy mô lớn (Ke et al. 2017) [6].
Trong nghiên cứu này, LightGBM Regressor được áp dụng để dự đoán Happiness Score dựa trên các đặc trưng về lối sống và sức khỏe. LightGBM là mô hình gradient boosting dựa trên cây với chiến lược phát triển cây leaf-wise, cho phép mô hình học hiệu quả các quan hệ phi tuyến phức tạp.
Các siêu tham số của mô hình được tối ưu thông qua Grid Search kết hợp cross-validation, sử dụng RMSE làm tiêu chí đánh giá. Những tham số quan trọng như số lượng cây, learning rate, độ sâu cây, số lá, tỷ lệ lấy mẫu dữ liệu và đặc trưng được điều chỉnh nhằm kiểm soát overfitting và cải thiện khả năng tổng quát hóa.

Hình 8. Cơ chế phát triển cây theo lá (Leaf-wise Tree Growth) của LightGBM

6. *eXtreme Gradient Boosting (XGBoost)*

eXtreme Gradient Boosting (XGBoost) là một thuật toán ensemble dựa trên Gradient Boosting và Decision Tree, được đề xuất nhằm nâng cao hiệu suất và khả năng tổng quát hóa của mô hình (Chen & Guestrin, 2016) [7].
Khác với các phương pháp boosting truyền thống, XGBoost tối ưu hàm mục tiêu thông qua xấp xỉ Taylor bậc hai của hàm loss, sử dụng đồng thời gradient bậc nhất và Hessian (gradient bậc hai), giúp quá trình huấn luyện hội tụ nhanh và chính xác hơn. Hàm mục tiêu bao gồm thành phần loss đo sai số dự đoán và regularization áp dụng trực tiếp lên cấu trúc cây, từ đó hạn chế overfitting.
Ngoài ra, XGBoost hỗ trợ xử lý giá trị thiếu hiệu quả và cho phép xác định trọng số lá theo công thức đóng, giúp giảm chi phí tính toán. Nhờ những đặc điểm này, XGBoost là mô hình phi tuyến mạnh, được sử dụng rộng rãi trong các bài toán hồi quy và phân loại với dữ liệu có quan hệ phức tạp.
Trong nghiên cứu này, XGBoost Regressor được sử dụng để dự đoán Happiness Score dựa trên các đặc trưng liên quan đến lối sống và sức khỏe tinh thần, bao gồm chất lượng chế độ ăn, mức độ hoạt động thể chất, thời gian ngủ, giờ làm việc, mức độ căng thẳng, thói quen hút thuốc và tiêu thụ rượu bia.
Mô hình được huấn luyện theo cơ chế gradient boosting với hàm mất mát squared error. Tập siêu tham số được tối ưu bằng Grid Search kết hợp cross-validation, trong đó tiêu chí đánh giá là Root Mean Squared Error (RMSE). Các tham số quan trọng như số lượng cây, learning rate, độ sâu cây, tỷ lệ lấy mẫu dữ liệu và đặc trưng được tinh chỉnh nhằm cân bằng giữa độ chính xác và khả năng tổng quát hóa.

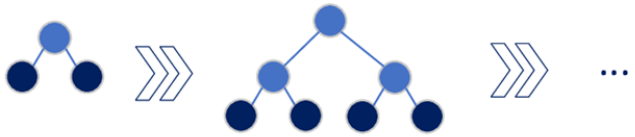

Hình 9. Cơ chế phát triển cây theo mức (Level-wise Tree Growth) của XGBoost

7. *Categorical Boosting (CatBoost)*

Categorical Boosting (CatBoost) là một thuật toán Gradient Boosting trên cây quyết định được phát triển bởi Yandex và được tối ưu đặc biệt cho dữ liệu hỗn hợp — cả biến số

(numerical) và biến phân loại (categorical) — mà không cần xử lý phức tạp trước.
Cách hoạt động:
Bước 1: Biến đổi đặc trưng

- Tự động xử lý các biến phân loại bằng Order-based Target Statistics.
- Tránh rò rỉ thông tin khi mã hóa dữ liệu.

Bước 2: Xây dựng cây quyết định

- Áp dụng Ordered Boosting: không dùng dữ liệu tương lai để huấn luyện, tránh overfitting.
- Xây dựng nhiều cây quyết định nhỏ theo từng vòng lặp. Mỗi cây mới cố gắng sửa lỗi còn lại của dự đoán trước đó.

Bước 3: Huấn luyện mô hình

- Với mỗi vòng lặp: tính gradient → xây cây mới → cập nhật mô hình.
- Tiếp tục cho đến khi đạt số vòng hoặc điều kiện dừng sớm.

Bước 4: Dự đoán

- Cộng đầu ra từ tất cả các cây đã học để đưa ra kết quả cuối cùng.
- Hỗ trợ cả bài toán phân loại và hồi quy.

Ưu điểm: Tự động xử lý biến phân loại bằng Ordered Target Statistics, không cần one-hot encoding thủ công; Giảm overfitting và data leakage nhờ kỹ thuật Ordered Boosting và các cơ chế regularization nội tại; Phù hợp với dữ liệu hỗn hợp (numeric + categorical), xử lý trực tiếp các biến như Stress_Level, Diet_Quality, Smoking_Habit, Alcohol_Consumption; Tổng quát hóa tốt trên tập dữ liệu vừa và nhỏ, đặc biệt khi các biến có mối quan hệ phức tạp; Hiệu suất cao, tối ưu cho cả GPU và CPU.

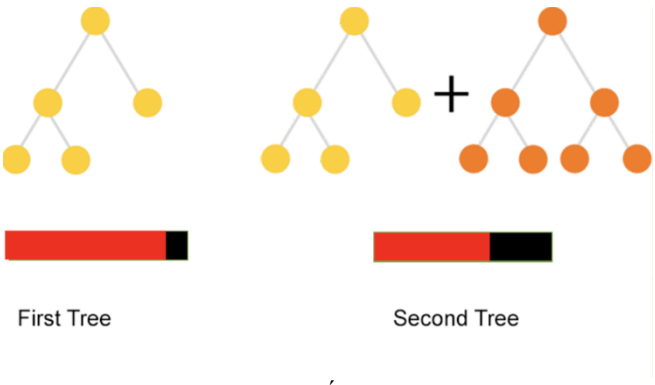

Hình 10. Minh họa cơ chế Boosting trong CatBoost

D. Phương pháp đánh giá

Để đo lường hiệu quả và độ chính xác của các mô hình trong việc dự báo Chỉ số hạnh phúc, nhóm sử dụng hệ thống 5 chỉ số đánh giá tiêu chuẩn bao gồm: MAE, MSE, RMSE, R-squared (R^2) và Explained Variance Score. Chi tiết các chỉ số được định nghĩa như sau:

1. Mean Absolute Error - MAE

MAE đo lường trung bình độ lớn của các sai số trong tập dự đoán mà không xem xét chiều hướng của chúng (dương hay âm). Đây là chỉ số trực quan nhất vì nó biểu thị khoảng cách trung bình giữa giá trị dự báo và giá trị thực tế trên cùng một đơn vị đo. Giá trị MAE càng nhỏ, mô hình dự báo càng chính xác.

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

2. Mean Squared Error - MSE

MSE tính toán trung bình của bình phương các sai số. Bằng cách bình phương sai số, MSE trừng phạt các sai số lớn (outliers) nặng hơn so với các sai số nhỏ. Điều này giúp phát hiện liệu mô hình có tạo ra những dự đoán sai lệch quá lớn hay không. Giá trị MSE càng gần 0 càng tốt.

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

3. Root Mean Squared Error – RMSE

RMSE là căn bậc hai của MSE. Ưu điểm của RMSE so với MSE là nó đưa đơn vị đo lường sai số về cùng đơn vị với biến mục tiêu (Chỉ số hạnh phúc), giúp việc giải thích kết quả trở nên dễ dàng hơn. RMSE càng nhỏ cho thấy độ lệch chuẩn của phần dư càng thấp, tức là các điểm dữ liệu tập trung sát đường hồi quy.

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

4. R-squared - R^2

R^2 (hay hệ số quyết định) cho biết tỷ lệ phần trăm sự biến thiên của biến phụ thuộc (Chỉ số hạnh phúc) có thể dự đoán được từ các biến độc lập (thói quen sinh hoạt). R^2 thường nằm trong khoảng từ 0 đến 1 (hoặc biểu diễn dưới dạng phần trăm). Giá trị càng gần 1 (hoặc 100%) nghĩa là mô hình càng giải thích tốt sự thay đổi của dữ liệu.

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

5. Explained Variance Score - EV

Chỉ số này đo lường mức độ mà mô hình toán học giải thích được sự phân tán (phương sai) của tập dữ liệu nhất định. Về cơ bản, nó tương tự như R^2 nhưng tập trung vào phần phương sai của sai số. Giá trị tốt nhất là 1.0, giá trị càng thấp thể hiện khả năng dự báo càng kém. Nếu Explained Variance bằng R^2, điều đó có nghĩa là sai số trung bình của mô hình bằng 0 (mô hình không bị chệch - unbiased).

$$EV(y, \hat{y}) = 1 - \frac{Var(y-\hat{y})}{Var(y)}$$

IV. KẾT QUẢ

Bảng 3. Bảng so sánh hiệu suất các mô hình dự đoán

Mô hình	MAE	MSE	RMSE	R^2	EV
CatBoost	0.2863	0.1219	0.3492	0.9438	0.9438
XGBoost	0.2901	0.1246	0.3530	0.9426	0.9426
LightGBM	0.2907	0.1251	0.3537	0.9424	0.9424
MLP	0.2239	0.0768	0.2770	0.9232	0.9428

KNN	0.2757	0.1178	0.3432	0.8821	0.8823
Lasso Regression	N/A	0.1682	0.4101	0.8317	N/A
Linear Regression	0.3309	0.1689	0.4110	0.8309	0.8309

Qua quá trình thực nghiệm trên bộ dữ liệu về thói quen sinh hoạt và chỉ số hạnh phúc, các mô hình đã cho thấy những kết quả đa dạng. Các chỉ số R^2 dao động từ 0.83 đến trên 0.94, cho thấy việc lựa chọn các đặc trưng đầu vào (Diet, Sleep, Stress...) là hoàn toàn hợp lý và có ý nghĩa thống kê cao.

Dựa trên bảng kết quả, có thể chia các mô hình thành 3 nhóm hiệu suất:

- Nhóm hiệu suất trung bình: Gồm Linear Regression và Lasso Regression.
- Nhóm hiệu suất khá: Mô hình KNN
- Nhóm hiệu suất xuất sắc: Gồm MLP và các thuật toán Boosting (LightGBM, XGBoost, CatBoost)

Nhóm mô hình tuyến tính (Linear/Lasso) và KNN có chỉ số R^2 thấp nhất trong bảng xếp hạng. Điều này phản ánh rằng mối quan hệ giữa các thói quen sinh hoạt và chỉ số hạnh phúc không đơn thuần là các quan hệ tuyến tính hay dựa trên khoảng cách đơn giản. Do đó, các mô hình này chưa đủ độ phức tạp để nắm bắt toàn bộ quy luật của dữ liệu.

Sự cạnh tranh chính diễn ra giữa mạng nơ-ron MLP và các thuật toán Boosting (đặc biệt là CatBoost). Mặc dù mô hình MLP đạt được sai số RMSE thấp nhất (0.2770), nhưng chỉ số R^2 của nó lại thấp hơn so với nhóm Boosting (0.9232 so với ~0.94).

Trong bài toán hồi quy này, mục tiêu quan trọng nhất của là tìm ra mô hình có mức độ phù hợp cao nhất đối với tổng thể dữ liệu. Chỉ số R^2 đại diện cho khả năng giải thích sự biến thiên của biến mục tiêu dựa trên các biến đầu vào.

Dựa trên tiêu chí ưu tiên tối đa hóa R^2, CatBoost đã chứng minh là mô hình vượt trội nhất với kết quả $R^2 = 0.9438$. CatBoost giải thích được tới 94.38% sự thay đổi của Chỉ số hạnh phúc dựa trên các thói quen sinh hoạt. Đây là một tỷ lệ rất cao, khẳng định mô hình đã học được gần như trọn vẹn các mẫu hình (patterns) tiềm ẩn trong dữ liệu. Dù XGBoost và LightGBM cũng rất mạnh, CatBoost vẫn nhỉnh hơn (0.9438 so với 0.9426 và 0.9424). Điều này cho thấy thuật toán xử lý dữ liệu hạng mục (categorical features) và cơ chế tree-building của CatBoost hoạt động hiệu quả hơn đối với bộ dữ liệu này. Chỉ số Explained Variance (EV) của CatBoost cũng đạt mức cao nhất (0.9438), tương đồng tuyệt đối với R^2, cho thấy mô hình không bị chệch (unbiased) và có tính ổn định cao.

Tổng hợp lại, mặc dù MLP có lợi thế về sai số tuyệt đối nhỏ, nhưng CatBoost mới là mô hình cân bằng và toàn diện nhất xét trên khía cạnh giải thích phương sai của dữ liệu. Với chỉ số R^2 cao nhất (0.9438), CatBoost được lựa chọn làm mô hình chính thức để dự báo và phân tích các yếu tố ảnh hưởng đến chỉ số hạnh phúc trong nghiên cứu này.

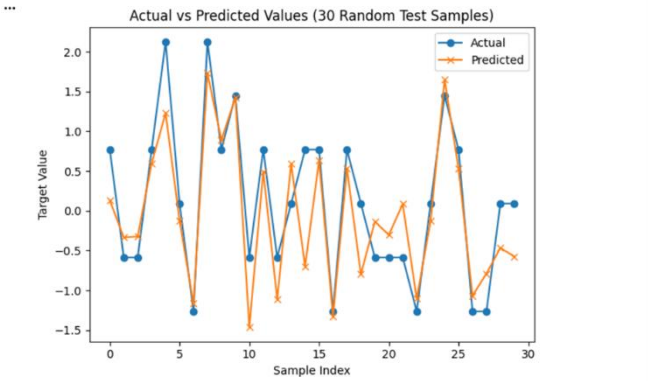

Hình 11. Kết quả dự đoán của Linear Regression

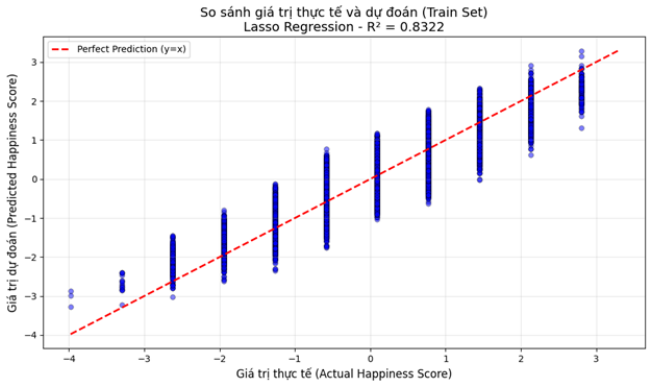

Hình 12. Kết quả dự đoán của Lasso Regression

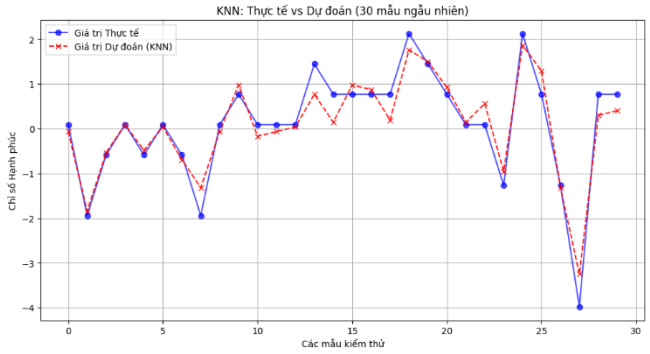

Hình 13. Kết quả dự đoán của KNN

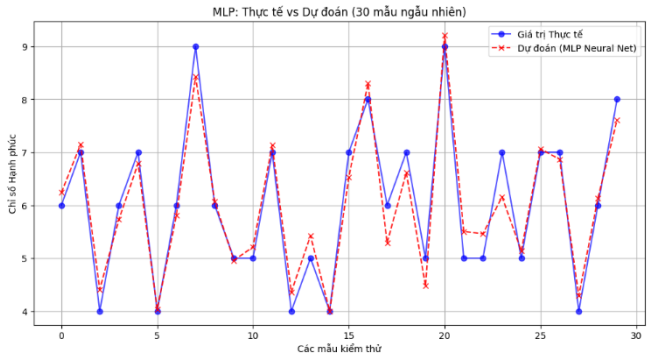

Hình 14. Kết quả dự đoán của MLP

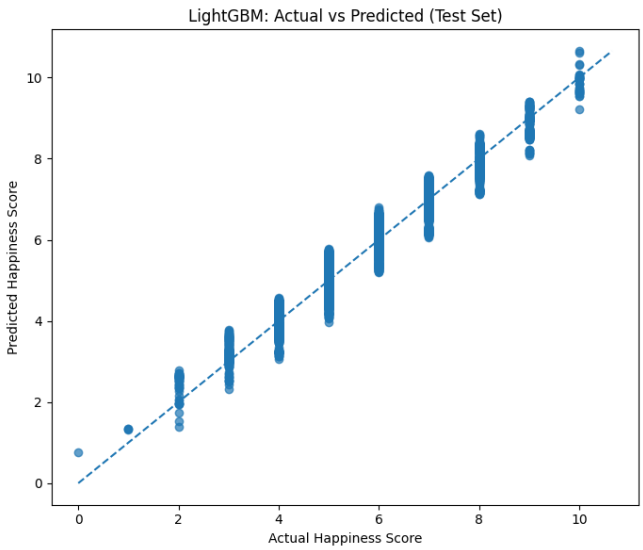

Hình 15. Kết quả dự đoán của LightGBM

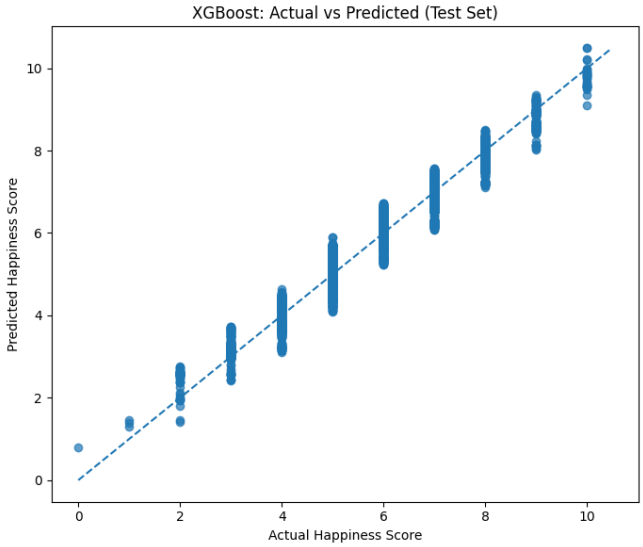

Hình 16. Kết quả dự đoán của XGBoost

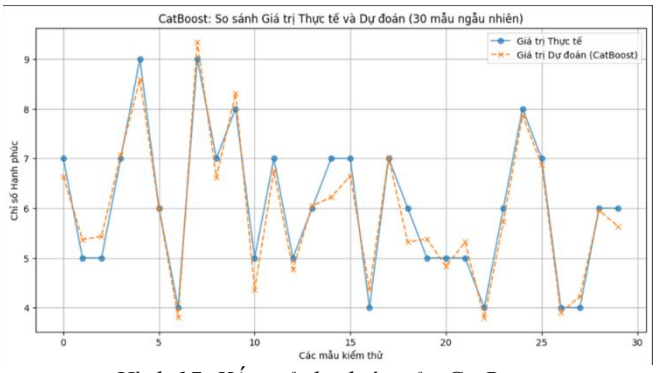

Hình 17. Kết quả dự đoán của CatBoost

V. KHUYẾN NGHỊ

Dựa trên kết quả phân tích Tầm quan trọng của đặc trưng từ mô hình CatBoost (Hình 23), nhóm đề xuất các giải pháp tác động vào các yếu tố cấu thành nên Chỉ số hạnh phúc, được chia theo thứ tự ưu tiên tác động:

1. *Giờ làm việc (Work Hours) - Hạng 1*

Với Người lao động: Cần xác định rõ "khung giờ vàng" để làm việc tập trung năng suất cao, tránh kéo dài thời gian làm việc vô ích. Thiết lập ranh giới giữa công việc và nghỉ ngơi, hạn chế mang việc về nhà.

Với Doanh nghiệp: Chuyển dịch từ quản lý theo thời gian sang quản lý theo hiệu quả công việc. Khuyến khích nhân viên về đúng giờ và hạn chế giao việc sát giờ tan tầm.

2. *Hoạt động thể chất (Physical Activity Hours) - Hạng 2*

Với Người lao động: Tận dụng mọi cơ hội để vận động (đi thang bộ, đứng lên đi lại sau mỗi giờ làm việc). Duy trì thói quen tập luyện ít nhất 30 phút/ngày (chạy bộ, gym, yoga).

Với Doanh nghiệp: Tài trợ chi phí tập luyện, thành lập các CLB thể thao nội bộ (bóng đá, cầu lông). Cân nhắc trang bị bàn làm việc đứng tại văn phòng.

3. *Tình trạng sức khỏe tinh thần (Mental Health Condition) - Hạng 3*

Với Người lao động: Tự trang bị kỹ năng sơ cứu cảm xúc, thực hành thiền định hoặc viết nhật ký để giải tỏa. Không ngần ngại tìm kiếm sự giúp đỡ chuyên nghiệp khi cảm thấy bất ổn kéo dài.

Với Doanh nghiệp: Xóa bỏ định kiến về sức khỏe tâm thần tại nơi làm việc. Cung cấp gói bảo hiểm bao gồm trị liệu tâm lý hoặc chương trình Hỗ trợ nhân viên tư vấn 24/7.

4. *Giờ ngủ (Sleep Hours) - Hạng 4*

Với Người lao động: Duy trì kỷ luật giấc ngủ (ngủ đủ 7-8 tiếng, đi ngủ và thức dậy đúng giờ). Hạn chế sử dụng thiết bị điện tử (ánh sáng xanh) trước khi ngủ 1 tiếng.

Với Doanh nghiệp: Tôn trọng "Quyền ngắt kết nối" – không nhắn tin, email công việc vào ban đêm để đảm bảo nhân viên có giấc ngủ trọn vẹn.

5. *Mức độ căng thẳng (Stress Level) - Hạng 5*

Với Người lao động: Nhận diện sớm các nguồn gây stress để xử lý hoặc né tránh. Học kỹ năng quản lý thời gian và sắp xếp công việc để tránh tình trạng "nước đến chân mới nhảy".

Với Doanh nghiệp: Đánh giá định kỳ tải trọng công việc của nhân viên để điều chỉnh phù hợp. Tổ chức các khóa đào tạo về Quản trị cảm xúc và Kiểm soát căng thẳng.

6. *Chất lượng ăn uống (Diet Quality) - Hạng 6*

Với Người lao động: Chú trọng chế độ ăn cân bằng dinh dưỡng, hạn chế đồ ăn nhanh và thực phẩm chế biến sẵn. Ưu tiên tự chuẩn bị bữa ăn trưa để kiểm soát chất lượng thực phẩm.

Với Doanh nghiệp: Nếu có canteen, cần cung cấp các lựa chọn thực phẩm lành mạnh. Thay thế các máy bán nước ngọt có ga bằng nước trái cây hoặc nước lọc miễn phí tại văn phòng.

7. *Tiêu thụ rượu bia (Alcohol Consumption) - Hạng 7*

Với Người lao động: Sử dụng rượu bia có chừng mực, tránh lạm dụng chất cồn như một phương pháp để giải tỏa stress (vì sẽ gây tác dụng ngược lên hệ thần kinh).

Với Doanh nghiệp: Thay đổi văn hóa "nhậu nhẹt" sau giờ làm. Các buổi Team Building nên hướng đến các hoạt động trải nghiệm, vận động hoặc sáng tạo thay vì chỉ tập trung vào tiệc tùng ăn uống.

8. *Thói quen hút thuốc (Smoking Habit) - Hạng 8*

Với Người lao động: Nhận thức rõ tác hại của thuốc lá đến sức khỏe phổi và mức độ stress (nicotine gây lệ thuộc và tăng lo âu khi thiếu thuốc). Lên kế hoạch cai thuốc lá dần dần.

Với Doanh nghiệp: Xây dựng môi trường làm việc "Không khói thuốc". Có các chương trình thi đua hoặc phần thưởng khích lệ cho những nhân viên cai thuốc lá thành công.

Kết luận: Việc cải thiện chỉ số hạnh phúc không chỉ dựa vào một yếu tố đơn lẻ. Sự phối hợp đồng bộ giữa ý thức tự giác của người lao động và chính sách hỗ trợ của doanh nghiệp sẽ tạo ra hiệu quả cộng hưởng, mang lại môi trường làm việc hạnh phúc và bền vững.

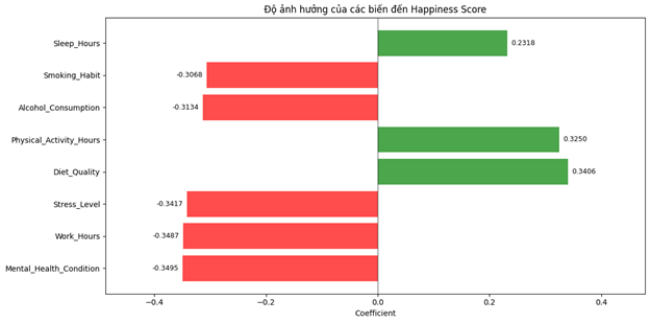

Hình 18. Mức độ ảnh hưởng của các biến (Lasso Regression)

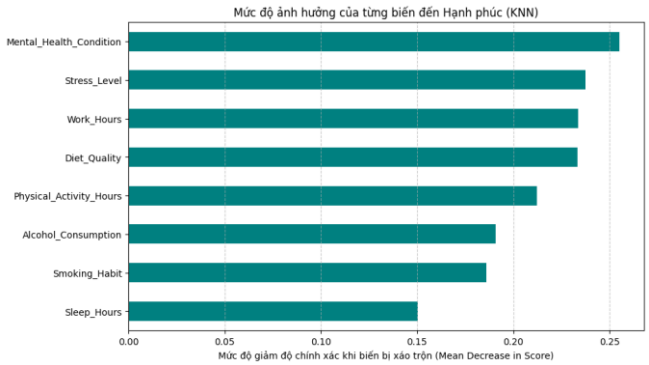

Hình 19. Mức độ ảnh hưởng của các biến (KNN)

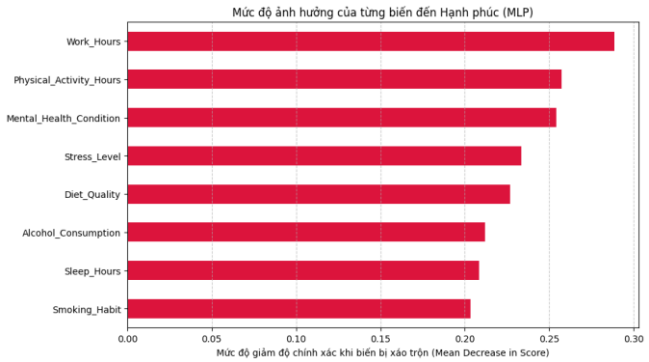

Hình 20. Mức độ ảnh hưởng của các biến (MLP)

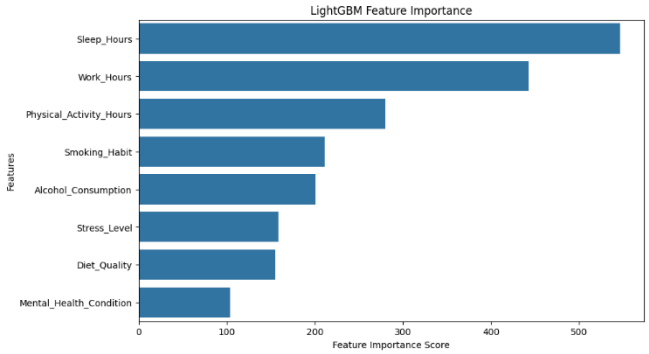

Hình 21. Mức độ ảnh hưởng của các biến (LightGBM)

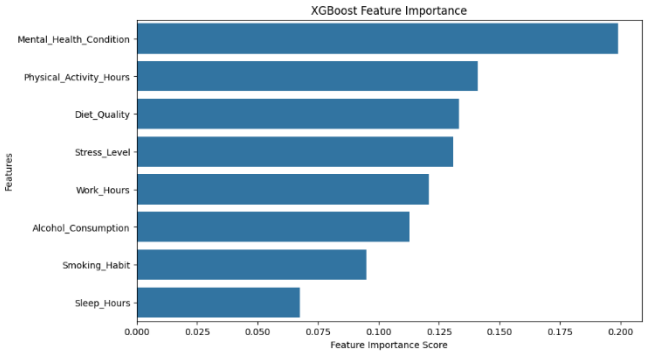

Hình 22. Mức độ ảnh hưởng của các biến (XGBoost)

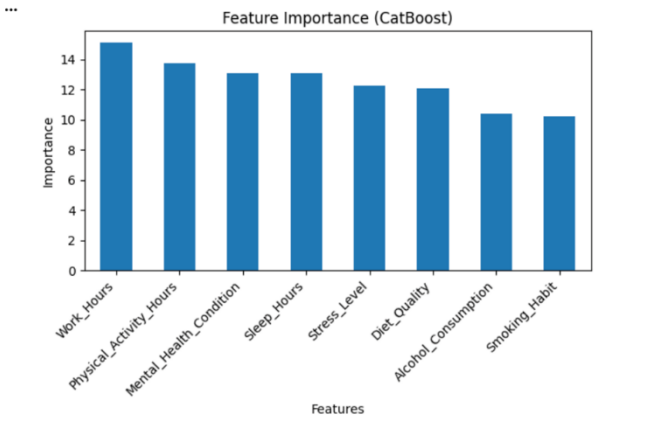

Hình 23. Mức độ ảnh hưởng của các biến (CatBoost)

VI. TÀI LIỆU THAM KHẢO

[1] M. A. Hamja, M. Hasan, M. A. Rashid, and M. T. H. Shourov, "Exploring happiness factors with explainable ensemble learning in a global pandemic," PLoS ONE, vol. 20, no. 1, Art. no. e0313276, Jan. 2025.

[2] B. Yang and X. Xie, "Analyzing and predicting global happiness index via integrated multilayer clustering and machine learning models," PLoS ONE, vol. 20, no. 4, Art. no. e0322287, Apr. 2025.

[3] K. Akanbi, Y. Jones, S. Oluwadare, and I. K. Nti, "Predicting happiness index using machine learning," 2024 IEEE 3rd International Conference on Computing and Machine Intelligence (ICMI), Apr. 2024, doi: 10.1109/ICMI60790.2024.10586193.

[4] Y. Feng, "A data-driven analysis for the world happiness," Preprints, Art. no. 2025060997, Jun. 2025, doi: 10.20944/preprints202506.0997.v1.

[5] S. Çelik, B. Doğanlı, M. Ü. Şaşmaz, and U. Akkucuk, "Accuracy comparison of machine learning algorithms on world happiness index data," Mathematics, vol. 13, no. 7, Art. no. 1176, Apr. 2025.

[6] G. Ke et al., "LightGBM: A Highly Efficient Gradient Boosting Decision Tree," in Advances in Neural Information Processing Systems 30 (NIPS 2017), Long Beach, CA, USA, 2017.

[7] T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," in Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16), San Francisco, CA, USA, Aug. 2016, pp. 785–794.